



T.C.

NİĞDE ÖMER HALİSDEMİR ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ

Yapay Zeka Teknikleri Dersi Projesi

Anomali Tespiti

Emre KARATOP - 220610006

1. Giriş

1.1. Problem Tanımı

Günümüzde dijital bankacılık işlemlerinin hacmi katlanarak artmaktadır. Bu artışla birlikte, finansal dolandırıcılık (fraud) girişimleri ve sistemsiz hatalar da daha karmaşık hale gelmektedir. Geleneksel kural tabanlı kontrol sistemleri (örneğin; "tutar 50.000 TL üzerindeyse uyar" gibi), statik yapıları nedeniyle yeni nesil dolandırıcılık yöntemlerini veya müşteri davranışlarındaki ince sapmaları tespit etmekte yetersiz kalmaktadır.

Bu projede kullanılan bank_transactions_data_2.csv veri seti, 2512 adet banka işlemini ve bu işlemlere ait TransactionAmount (İşlem Tutarı), TransactionDuration (İşlem Süresi), LoginAttempts (Giriş Denemeleri), AccountBalance (Hesap Bakiyesi) ve Location (Konum) gibi çeşitli öznitelikleri içermektedir. Veri setindeki temel problem, binlerce yasal (normal) işlem arasından, sayıca çok az olan ancak finansal risk taşıyan "anormal" (outlier/anomaly) işlemleri otomatik ve doğru bir şekilde tespit edebilmektir. Bu bir "Denetimsiz Anormallik Tespiti" (Unsupervised Anomaly Detection) problemidir; çünkü hangi işlemin kesinlikle dolandırıcılık olduğuna dair önceden belirlenmiş bir etiket bulunmamaktadır ve sistemin normalden sapmaları kendisinin öğrenmesi gerekmektedir.

1.2. Amaç

Bu projenin temel amacı, bankacılık verileri üzerinde farklı istatistiksel ve makine öğrenmesi tabanlı yöntemleri uygulayarak anormallikleri tespit etmek ve finansal güvenliği artırıcı bir karar destek mekanizması oluşturmaktır.

Bu genel amaç doğrultusunda projenin alt hedefleri şunlardır:

1. Algoritmaların Karşılaştırılması: Tek değişkenli (Univariate) yöntemler olan Z-Score ve Grubbs Testi ile çok değişkenli (Multivariate) yöntemler olan Isolation Forest ve DBSCAN algoritmalarının performanslarını ve tespit ettikleri anormallik türlerini karşılaştırmak.
2. Karmaşık İlişkilerin Keşfi: Sadece yüksek tutarlı işlemleri değil; "düşük tutarlı ancak çok kısa sürede gerçekleşen" veya "hesap bakiyesi ile uyumsuz işlem sıklığına sahip" gibi karmaşık ve insan gözünden kaçabilecek şüpheli örüntüleri Isolation Forest gibi yöntemlerle ortaya çıkarmak.
3. Görselleştirme ve Yorumlama: Tespit edilen anormallikleri grafikler üzerinde görselleştirerek, bu işlemlerin neden "anormal" olarak etiketlendiğini (örneğin; yoğunluktan uzak olmaları veya karar ağacında hızlı izole edilmeleri) analitik olarak yorumlamak.
4. Güvenlik İçin İlgörü Sağlama: Bankanın güvenlik ekiplerine, potansiyel dolandırıcılık vakalarını önceliklendirebilecekleri, veri odaklı bir filtreleme sistemi sunmak.

2. Gelişme

2.1. Kullanılan Veri Seti : Online Retail

Bu projede, bankacılık işlemlerine ait finansal hareketleri ve müşteri davranışlarını içeren bank_transactions_data_2.csv isimli veri seti kullanılmıştır. Veri seti, toplam 2512 adet gözlem (satır) ve 16 adet öznitelikten (sütun) oluşmaktadır. Veri setinde eksik değer (missing value) veya tekrar

eden kayıt (duplicate) bulunmamakta olup, veri kalitesi anormallik tespiti algoritmalarının doğrudan uygulanması için uygundur.

Veri setindeki öznitelikler, anormallik tespiti açısından üç ana kategoride değerlendirilmiştir:

1. İşlem Karakteristikleri (Transaction Features)

Bu özellikler, işlemin finansal boyutunu ve zamanlamasını tanımlar.

- TransactionID: İşlemin benzersiz kimlik numarasıdır.
- TransactionAmount (Sayısal): İşlemin parasal tutarıdır. Tek değişkenli anormallik tespiti (Z-Score) için temel değişkendir.
- TransactionDate: İşlemin gerçekleştiği tarih ve saat bilgisidir.
- TransactionDuration (Sayısal): İşlemin ne kadar sürede tamamlandığıdır. Çok kısa süren işlemler bot veya otomatik saldırı şüphesi taşıyabilir.
- TransactionType: İşlemin türünü (Kredi, Banka Kartı vb.) belirtir.

2. Müşteri ve Hesap Bilgileri (Customer & Account Features)

Müşterinin demografik yapısı ve finansal durumu hakkında bilgi verir.

- AccountID: Müşteri hesap numarasıdır.
- AccountBalance (Sayısal): İşlem anındaki hesap bakiyesidir. İşlem tutarı ile bakiye arasındaki dengesizlikler (Isolation Forest için) önemli bir göstergedir.
- CustomerAge: Müşterinin yaşıdır.
- CustomerOccupation: Müşterinin meslek bilgisidir.

3. Güvenlik ve Teknik Veriler (Security & Technical Features)

Dolandırıcılık (Fraud) tespiti için en kritik verileri içerir.

- LoginAttempts (Sayısal): İşlem öncesi yapılan giriş denemesi sayısıdır. 1'den fazla deneme, potansiyel bir yetkisiz erişim girişimine (Brute-force) işaret edebilir.
- Location: İşlemin yapıldığı coğrafi konumdur.
- IP Address & DeviceID: İşlemin yapıldığı cihaz ve ağ bilgileridir.
- Channel: İşlemin yapıldığı kanaldır (ATM, Online, Mobil vb.).

2.2. Kullanılan Yöntem ve Algoritmalar

Bu çalışmada, bankacılık verileri üzerindeki anormallikleri tespit etmek amacıyla "Denetimsiz Öğrenme" (Unsupervised Learning) yaklaşımı benimsenmiştir. Veri setindeki işlemlerin "normal" veya "dolandırıcılık" şeklinde önceden etiketlenmemiş olması nedeniyle, verinin kendi iç yapısındaki sapmaları ve yoğunluk farklarını analiz eden algoritmalar tercih edilmiştir. Çalışmada, tek değişkenli (univariate) istatistiksel yöntemler ile çok değişkenli (multivariate) makine öğrenmesi yöntemleri karşılaştırmalı olarak kullanılmıştır.

1. Z-Skoru (Z-Score) Analizi

Z-Skoru, istatistiksel tabanlı en temel anormallik tespiti yöntemlerinden biridir. Verinin Gauss (Normal) dağılımına uyduğu varsayımıyla çalışır. Bu yöntem, bir veri noktasının veri setinin genel ortalamasından ne kadar saptığını standart sapma cinsinden ifade eder.

2. Isolation Forest (İzolasyon Ormanı)

Isolation Forest, özellikle büyük boyutlu veri setlerinde anormallik tespiti için geliştirilmiş, ağaç tabanlı bir makine öğrenmesi algoritmasıdır. Diğer yöntemlerin aksine, "normal" veriyi modellemeye çalışmaz; doğrudan "anormal" veriyi izole etmeye odaklanır.

Çalışma Prensipleri: Algoritma, anormalliklerin "sayıca az" ve "özellikleri bakımından farklı" olduğu prensibine dayanır. Veri seti üzerinde rastgele karar ağaçları oluşturur. Normal verileri diğerlerinden ayırmak için çok sayıda dallanma (karar kuralı) gerekirken, aykırı değerler (anormallikler) genellikle kök düğüme yakın, az sayıda dallanma ile izole edilebilirler.

Uygulama: Projede; Tutar, Süre, Bakiye ve Giriş Denemesi gibi çoklu değişkenler bir arada kullanılarak, tek bir değişkende görünmeyen ancak kombinasyonel olarak şüpheli olan işlemler (örneğin; düşük bakiye ile yüksek tutarlı harcama) tespit edilmiştir. Kirlilik oranı (contamination) parametresi ile en şüpheli %5'lik dilim hedeflenmiştir.

3. DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN, veri noktalarının yoğunluğuna dayalı bir kümeleme algoritmasıdır. Anormallik tespitinde, verinin yoğun olduğu bölgeleri "küme", seyrek bölgelerde kalan noktaları ise "gürültü" (noise) olarak sınıflandırmak için kullanılır.

Çalışma Prensipleri: Algoritma iki temel parametre kullanır: eps (komşuluk yarıçapı) ve min_samples (bir küme oluşması için gereken minimum nokta sayısı). Bir noktanın eps yarıçapı içinde min_samples kadar komşusu yoksa ve herhangi bir kümenin sınırında da değilse, bu nokta "Gürültü/Anormallik" olarak işaretlenir.

Uygulama: Veriler öncelikle StandardScaler ile ölçeklendirilmiş, ardından DBSCAN uygulanmıştır. Bu yöntem, özellikle belirli davranış kalıplarına (kümelere) uymayan, uzayda yalnız kalan işlemleri tespit etmekte etkilidir.

4. Grubbs Testi

Grubbs testi, tek değişkenli bir veri setinde (univariate) istatistiksel olarak anlamlı tek bir aykırı değer olup olmadığını belirlemek için kullanılan bir hipotez testidir.

Çalışma Prensipleri: Test, "Veri setinde aykırı değer yoktur" ve "Veri setinde en az bir aykırı değer vardır" hipotezlerini kurar. Veri setindeki ortalamadan en uzak değerın sapma miktarını hesaplar ve bunu kritik tablo değeriyle karşılaştırır.

Uygulama: Projede TransactionAmount üzerinde uygulanmıştır. Z-Score'dan farkı, matematiksel kesinlik sağlamasıdır; ancak yinelemeli (iteratif) uygulanmadığı sürece sadece en baskın anormalliği bulur. Bu nedenle, en uçtaki ekstrem durumu doğrulamak için kullanılmıştır.

3. Sonuç ve Değerlendirme

3.1. Z-Skoru (Z-Score) Analizi

TransactionAmount (İşlem Tutarı) değişkeni üzerinde yapılan Z-Skoru analizi sonucunda, standart sapma eşik değeri ± 3 olarak belirlenmiştir. Analiz sonucunda veri setindeki 2512 işlemten 48 adet işlem anormallik olarak tespit edilmiştir.

Z-Skoru algoritması, tek değişkenli (univariate) bir yaklaşım sergilediği için yalnızca tutar bakımından aşırı uçta olan (çok yüksek meblağlı) işlemleri yakalamıştır. Grafikte (Şekil 1) görüldüğü üzere, kırmızı ile işaretlenen noktalar, veri setinin genel dağılımının (ortalama ~300 birim) çok üzerinde yer alan işlemlerdir. Bu yöntem, ortalama tutarlarda gerçekleşen ancak süre veya konum açısından şüpheli olan işlemleri tespit etmekte yetersiz kalmıştır. Sadece "parasal büyüklüğe" odaklanan basit dolandırıcılık senaryoları için etkilidir.

3.2. Isolation Forest Analizi

İşlem Tutarı, İşlem Süresi, Hesap Bakiyesi ve Giriş Denemeleri gibi çoklu öznelilikler kullanılarak eğitilen Isolation Forest modeli, veri setinde toplam 126 adet anormallik tespit etmiştir. Kirlilik (contamination) oranı %5 olarak ayarlanmıştır.

Z-Skoru'nun aksine Isolation Forest, değişkenler arasındaki karmaşık ilişkileri ortaya çıkarmıştır. Grafikte (Şekil 2) TransactionDuration (Süre) ve TransactionAmount (Tutar) eksenleri incelendiğinde, algoritmanın sadece yüksek tutarlı işlemleri değil; düşük tutarlı olsa bile işlem süresi anormal derecede kısa veya uzun olan işlemleri de "anormal" olarak etiketlediği görülmektedir. Bu durum, yöntemin insan gözünden kaçabilecek, çok boyutlu ve sofistike dolandırıcılık girişimlerini yakalamada daha başarılı olduğunu göstermektedir.

3.3. DBSCAN Analizi

Veriler standartlaştırıldıktan sonra uygulanan DBSCAN algoritması ($\text{eps}=0.8$, $\text{min_samples}=10$), veri noktalarını yoğunluklarına göre kümelere ayırmış ve herhangi bir kümeye dahil olamayan 151 adet noktayı "gürültü" (noise) yani anormallik olarak sınıflandırmıştır.

DBSCAN, veri uzayındaki topolojik yapıyı en iyi analiz eden yöntem olmuştur. Grafikte (Şekil 3 - Bakiye ve Tutar ilişkisi) görüldüğü üzere, mavi noktalar müşterilerin genel davranış kalıbını temsil eden yoğun "normal" kümeleri oluştururken; kırmızı noktalar bu kümelerin dışında kalan, seyrek bölgelerdeki işlemleri temsil etmektedir. DBSCAN, en yüksek sayıda anormallik tespit eden algoritma olmuştur. Bu durum, veri setinde standart müşteri profiline uymayan (örneğin; çok düşük bakiyeli hesaplarda ani hareketler gibi) dağınık ve düzensiz işlem sayısının fazla olduğunu göstermektedir.

3.4. Grubbs Testi Analizi

TransactionAmount değişkeni üzerinde uygulanan Grubbs testi sonucunda, hesaplanan G değerinin kritik tablo değerinden büyük olduğu ($G_{\text{hesap}} > G_{\text{kritik}}$) görülmüş ve istatistiksel olarak anlamlı bir aykırı değer tespit edilmiştir.

Grubbs testi, veri setindeki en uçtaki (maksimum) değer in şans eseri oluşmadığını, bunun matematiksel olarak kanıtlanmış bir aykırı değer olduğunu doğrulamıştır. Bu test, tüm anormallikleri bulmak yerine "Bu veri setinde kesinlikle bir anormallik var mı?" sorusuna en güvenilir yanıtı veren yöntem olmuştur. Genellikle Z-Skoru gibi yöntemlerin bulgularını doğrulamak (validasyon) amacıyla kullanılması uygundur.

3.5. Değerlendirme

Algoritma	Tür	Tespit Edilen Anormallik Sayısı	Odaklandığı Kriter	Avantajı
Z-Score	İstatistiksel (Tek Değişken)	48	Sadece Tutar Büyüklüğü	Basit, hızlı ve aşırı yüksek tutarları bulmada net.
Grubbs	İstatistiksel (Tek Değişken)	1 (En uç değer)	Maksimum Sapma	İstatistiksel kesinlik sağlar, kanıt niteliğindedir.
Isolation Forest	Makine Öğrenmesi (Çok Değişken)	126	İlişkisel Sapmalar	Tutar, süre ve bakiye arasındaki gizli bağlantıları yakalar.
DBSCAN	Kümeleme (Çok Değişken)	151	Yoğunluk/Seyreklik	Müşteri profiline uymayan, uzayda yalnız kalan işlemleri bulur.

Sonuç: Projenin amacı olan finansal dolandırıcılık tespiti için Isolation Forest ve DBSCAN algoritmalarının, Z-Skoru ve Grubbs testine göre daha üstün performans gösterdiği sonucuna varılmıştır.

- **Z-Skoru**, sadece "zengin" veya "yüksek harcama yapan" müşterileri aykırı olarak işaretlerken;
- **Isolation Forest**, "hesabında para olmayan ama 5 saniyede işlem yapan" gibi şüpheli senaryoları yakalayabilmiştir.

Bu nedenle, gerçek zamanlı bir bankacılık güvenlik sisteminde, kural tabanlı kontrollerin (Z-Score gibi) ötesine geçilerek, Isolation Forest gibi anormalliği izole etmeye odaklanan makine öğrenmesi modellerinin kullanılması önerilmektedir.

4. Kaynak

- <https://www.kaggle.com/datasets/valakhorasani/bank-transaction-dataset-for-fraud-detection?resource=download>
- <https://www.komtas.com/glossary/anomali-tespiti-algoritmaları-nedir#:~:text=Anomali%20Tespiti%20Algoritma%20T%C3%BCrleri&text=Z%2Dscore%20analizi%2C%20Grubbs%20testi,daha%20karma%C5%9F%C4%B1k%20veri%20yap%C4%B1lar%C4%B1nda%20kullan%C4%B1l%C4%B1r.>

```
z_score.py > ...
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 from scipy import stats
6
7 filename = 'bank_transactions_data_2.csv'
8 try:
9     df = pd.read_csv(filename)
10    print(f"{filename} başarıyla yüklendi.")
11 except FileNotFoundError:
12    print(f"Hata: {filename} dosyası bulunamadı. Lütfen dosya yolunu kontrol edin.")
13    exit()
14
15 df['Z_Score'] = stats.zscore(df['TransactionAmount'])
16
17 THRESHOLD = 3
18 df['Anormallik_ZScore'] = df['Z_Score'].apply(lambda x: 'Anormal' if np.abs(x) > THRESHOLD else 'Normal')
19
20 anomalies = df[df['Anormallik_ZScore'] == 'Anormal']
21 print(f"\nToplam İşlem Sayısı: {len(df)}")
22 print(f"Tespit Edilen Anormallik Sayısı (Z > {THRESHOLD}): {len(anomalies)}")
23 print("\nÖrnek Anormallikler:")
24 print(anomalies[['TransactionID', 'TransactionAmount', 'Z_Score']].head())
25
26 plt.figure(figsize=(10, 6))
27 sns.scatterplot(data=df, x=df.index, y='TransactionAmount', hue='Anormallik_ZScore', palette={'Normal': 'blue', 'Anormal': 'red'})
28 plt.title(f'Z-Score Yöntemi ile Anormallik Tespiti (Eşik: {THRESHOLD})')
29 plt.xlabel('İşlem İndeksi')
30 plt.ylabel('İşlem Tutarı')
31 plt.legend()
32 plt.show()
```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS


PS C:\Users\Lab2-19\Desktop\Hafta 6> & C:\Users\Lab2-19\AppData\Local\Programs\Python\Python312\python.exe "c:/Users/Lab2-19/Desktop/Hafta 6/z_score.py"

bank_transactions_data_2.csv başarıyla yüklendi.

Toplam İşlem Sayısı: 2512
Tespit Edilen Anormallik Sayısı (Z > 3): 48

Örnek Anormallikler:

	TransactionID	TransactionAmount	Z_Score
74	TX000075	1212.51	3.134476
85	TX000086	1340.19	3.571903
176	TX000177	1362.55	3.648508
190	TX000191	1422.55	3.854066
274	TX000275	1176.28	3.010353




```
isolatin_forest.py > ...
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4 from sklearn.ensemble import IsolationForest
5
6 filename = 'bank_transactions_data_2.csv'
7 df = pd.read_csv(filename)
8
9 features = ['TransactionAmount', 'TransactionDuration', 'AccountBalance', 'LoginAttempts']
10 X = df[features]
11
12 iso_forest = IsolationForest(n_estimators=100, contamination=0.05, random_state=42)
13
14 preds = iso_forest.fit_predict(X)
15
16 df['Anomaly_Score'] = iso_forest.decision_function(X) # Skor ne kadar düşüğe o kadar anormal
17 df['Anormallik_IF'] = preds
18 df['Anormallik_Durumu'] = df['Anormallik_IF'].apply(lambda x: 'Anormal' if x == -1 else 'Normal')
19
20 anomalies = df[df['Anormallik_IF'] == -1]
21 print(f"Toplam Anormallik Sayısı: {len(anomalies)}")
22 print("\nIsolation Forest ile Bulunan Örnek Anormallikler:")
23 print(anomalies[features + ['Anomaly_Score']].head())
24
25 plt.figure(figsize=(10, 6))
26 sns.scatterplot(data=df, x='TransactionDuration', y='TransactionAmount', hue='Anormallik_Durumu', palette={'Normal': 'blue', 'Anormal': 'red'})
27 plt.title('Isolation Forest: İşlem Süresi ve Tutarı İlişkisi')
28 plt.xlabel('İşlem Süresi (Duration)')
29 plt.ylabel('İşlem Tutarı (Amount)')
30 plt.show()
```


PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

PS C:\Users\Lab2-19\Desktop\Hafta 6> & C:\Users\Lab2-19\AppData\Local\Programs\Python\Python312\python.exe "c:/Users/Lab2-19/Desktop/Hafta 6/isolatin_forest.py"

Toplam Anormallik Sayısı: 126

Isolation Forest ile Bulunan Örnek Anormallikler:

	TransactionAmount	TransactionDuration	AccountBalance	LoginAttempts	Anomaly_Score
26	246.93	158	673.35	5	-0.075150
32	396.45	168	9690.15	3	-0.014181
85	1340.10	30	8654.28	1	-0.018206
91	223.85	55	2929.91	4	-0.029888
146	973.39	296	2042.22	1	-0.016904
146	973.39	296	2042.22	1	-0.016904




```
db_scan.py > ...
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4 from sklearn.cluster import DBSCAN
5 from sklearn.preprocessing import StandardScaler
6
7 filename = 'bank_transactions_data_2.csv'
8 df = pd.read_csv(filename)
9
10 features = ['TransactionAmount', 'TransactionDuration', 'AccountBalance', 'LoginAttempts']
11 X = df[features]
12
13 scaler = StandardScaler()
14 X_scaled = scaler.fit_transform(X)
15
16 dbscan = DBSCAN(eps=0.8, min_samples=10)
17 clusters = dbscan.fit_predict(X_scaled)
18
19 df['Cluster'] = clusters
20 df['Anormallik_DBSCAN'] = df['Cluster'].apply(lambda x: 'Normal' if x == -1 else 'Normal (Küme ' + str(x) + ')')
21
22 anomalies = df[df['Cluster'] == -1]
23 print(f"Toplam Anormallik (Gürültü) Sayısı: {len(anomalies)}")
24 print("\nDBSCAN ile Bulunan Örnek Anormallikler:")
25 print(anomalies[features].head())
26
27 plt.figure(figsize=(10, 6))
28
29 sns.scatterplot(data=df, x='AccountBalance', y='TransactionAmount', hue='Anormallik_DBSCAN',
30                palette=sns.color_palette("bright", df['Anormallik_DBSCAN'].nunique()))
31 plt.title('DBSCAN: Hesap Bakiyesi vs İşlem Tutarı Kümeleme')
32 plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
33 plt.tight_layout()
34 plt.show()
```

PS C:\Users\Lab2-19\Desktop\Hafta 6> & C:\Users\Lab2-19\AppData\Local\Programs\Python\Python312\python.exe "c:/Users/Lab2-19/Desktop/Hafta 6/db_scan.py"

Toplam Anormallik (Gürültü) Sayısı: 151

DBSCAN ile Bulunan Örnek Anormallikler:

	TransactionAmount	TransactionDuration	AccountBalance	LoginAttempts
23	345.84	142	1402.50	3
26	246.93	158	673.35	5



```

grubbs_test.py > ...
1  import pandas as pd
2  import numpy as np
3  import scipy.stats as stats
4
5  def grubbs_test(data):
6      n = len(data)
7      mean_val = np.mean(data)
8      std_val = np.std(data, ddof=1)
9
10     abs_deviation = np.abs(data - mean_val)
11     max_deviation = np.max(abs_deviation)
12     max_idx = np.argmax(abs_deviation)
13
14     G_calculated = max_deviation / std_val
15
16     # Kritik Değer (Alpha 0.05)
17     t_dist = stats.t.ppf(1 - 0.05 / (2 * n), n - 2)
18     numerator = (n - 1) * np.sqrt(np.square(t_dist))
19     denominator = np.sqrt(n) * np.sqrt(n - 2 + np.square(t_dist))
20     G_critical = numerator / denominator
21
22     return max_idx, G_calculated, G_critical
23
24 filename = 'bank_transactions_data_2.csv'
25 df = pd.read_csv(filename)
26
27 data_column = df['TransactionAmount'].values
28
29 print("Grubbs Testi Başlatılıyor (TransactionAmount)...")
30
31 idx, G_calc, G_crit = grubbs_test(data_column)
32
33 print(f"\nHesaplanan G Değeri: {G_calc:.4f}")
34 print(f"Kritik G Değeri: {G_crit:.4f}")
35
36 if G_calc > G_crit:
37     print("\nSONUÇ: Bir aykırı değer (Outlier) tespit edildi!")
38     print(f"Satır İndeksi: {idx}")
39     print(f"Değer: {data_column[idx]}")
40     print(f"Satır Detay: \n{df.iloc[idx]}")
41 else:
42     print("\nSONUÇ: İstatistiksel olarak anlamlı tek bir aykırı değer bulunamadı.")

```

```

PS C:\Users\Lab2-19\Desktop\VeriFa 6x & C:\Users\Lab2-19\AppData\Local\Programs\Python\Python312\python.exe C:\Users\Lab2-19\Desktop\VeriFa 6\grubbs_test.py
Grubbs Testi Başlatılıyor (TransactionAmount)...
Grubbs Testi Başlatılıyor (TransactionAmount)...

Hesaplanan G Değeri: 5.5542
Hesaplanan G Değeri: 5.5542
Kritik G Değeri: 4.2587
Kritik G Değeri: 4.2587

SONUÇ: Bir aykırı değer (Outlier) tespit edildi!
Satır İndeksi: 653
Satır İndeksi: 653
Değer: 1919.11
Değer: 1919.11
Satır Detay:
Satır Detay:
TransactionID      TX000654
AccountID          AC00423
TransactionAmount  1919.11
TransactionDate    2023-06-27 17:48:25
TransactionDate    2023-06-27 17:48:25
TransactionType     Debit
Location            Portland
DeviceID           0000191
IP Address          207.157.126.125
MerchantID         M833
Channel             ATM
CustomerAge         38
CustomerAge         38
CustomerOccupation  Doctor
TransactionDuration 161
LoginAttempts       1
CustomerOccupation  Doctor
TransactionDuration 161
LoginAttempts       1
TransactionDuration 161
LoginAttempts       1
AccountBalance      11090.24
PreviousTransactionDate 2024-11-04 08:18:27
Name: 653, dtype: object
PS C:\Users\Lab2-19\Desktop\VeriFa 6x >

```